

Relation élèves enseignants

Barbeau Faustine - Combes Florent - Dumas Elouan - Malzieu Yann

Table des matières

Relation élèves enseignants	2
Installation des packages	2
Import des données	2
Intro blabla	2
Sélection et gestion des variables	2
Etude des valeurs manquantes	4
Partie 1	6
Partie II	8
partie III	9

Relation élèves enseignants

Installation des packages

Import des données

```
data <- readRDS("stu_qqq.rds")
```

```
dim(data)
```

```
[1] 613744 1278
```

Par souci d'efficacité, le jeu de données contenant plus de 600.000 individus, nous élaborerons nos analyses exploratoires sur un échantillon de 5% de celui-ci.

Intro blabla

Sélection et gestion des variables

–blabla sélection de variables

On décide ici de dicerner plusieurs types de variables, notamment celles en lien direct avec l'enseignant, celles concernant les cours de mathématiques, celles concernant la créativité, et les autres.

On les conserve toutes et on aura l'occasion de créer des jeux de données distincts selon les types de variables.

Celles-ci seront nos variables explicatives.

```
Notes <- data %>% select(starts_with("PV"))
Notes_NA <- data %>% select(starts_with("PV"))
Notes_NA <- lapply(Notes_NA, as.numeric)
moyennes_NA <- lapply(Notes_NA, mean, na.rm = FALSE)
```

```
matieres <- c(
  "MATH", #Mathématiques générales
  "READ", #Lecture
  "SCIE", #Science
  "MCCR", #Mathématiques : Changement et relation
  "MCQN", #Mathématiques : Quantitatif
  "MCSS", #Mathématiques : Espace et formes
  "MCUD", #Mathématiques : Incertitude et données
  "MPEM", #Mathématiques : Employer des concepts mathématiques, définitions et théorèmes
  "MPFS", #Mathématiques : Formuler des situations mathématiquement
  "MPIN", #Mathématiques : Interpréter, appliquer et analyser des sorties mathématiques
  "MPRE" #Mathématiques : Raisonnement
)
```


```
Notes_moyennes <- as.data.frame(
  sapply(matieres, function(m) {
    vars <- paste0("PV", 1:10, m)
    rowMeans(Notes[, vars], na.rm = TRUE)
  })
)

colnames(Notes_moyennes) <- paste0("MOY_", matieres)

Notes_moyennes$MOY_GENERALE <- rowMeans(Notes_moyennes, na.rm = TRUE)

cor_mat <- cor(
  Notes_moyennes[, grep("^MOY_", names(Notes_moyennes))],
  use = "pairwise.complete.obs"
)

corrplot(
  cor_mat,
  method = "number",
  type = "upper",
  tl.col = "black",
  tl.srt = 45,
  number.cex = 0.8
)
```



```
matieres <- c(
  "MATH", #Mathématiques générales
  "READ", #Lecture
  "SCIE" #Science
)

Notes_moyennes <- as.data.frame(
  sapply(matieres, function(m) {
    vars <- paste0("PV", 1:10, m)
    rowMeans(Notes[, vars], na.rm = TRUE)
  })
)
```

```
colnames(Notes_moyennes) <- paste0("MOY_", matieres)

Notes_moyennes$MOY_GENERALE <- rowMeans(Notes_moyennes, na.rm = TRUE)

vars_collector <- c("RELATST", "TEACHSUP", "ESCS", "ST016Q01NA", "ST272Q01JA", "EXPWB", "BELONG",
vars_etude <- vars_collector[vars_collector %in% names(data)]

idx_vars_etude <- match(vars_etude, names(data))

data_etude <- c(data[, c(1, 26, idx_vars_etude), drop = FALSE], Notes_moyennes)
data_etude <- as.data.frame(data_etude)
```

Par ailleurs, les données de réponses aux questions sont décrites comme une échelle de 1 à 4 pour affirmer un total désaccord, un désaccord, un accord et un accord total. On aura l'occasion de transformer ces valeurs pour rendre le jeu plus clair, mais seulement après nos études préliminaires pour conserver la possibilité de calculer des statistiques de base (moyenne, médiane, EIQ...).

Regardons maintenant les types de nos variables :

```
str(data_etude)
```

On ne remarque pas de gros problème au sein nos types de variables. On peut malgré tout convertir en facteur celles qui ne sont pas destinées à élaborer des calculs.

```
data_etude$ST004D01T <- as.factor(data_etude$ST004D01T)
```

Etude des valeurs manquantes

Etudions les valeurs manquantes selon le pays des individus étudiés afin de mieux nous préparer à l'analyse monovariée :


```
prop_NA_par_ligne <- rowMeans(is.na(data))

pct_NA_par_pays <- tapply(prop_NA_par_ligne, data$CNT, mean) * 100

pct_NA_par_pays_tri <- sort(pct_NA_par_pays)

barplot(
  pct_NA_par_pays_tri,
  las = 2,
  col = "darkorange",
  main = "Proportion moyenne de NA par pays",
  ylab = "% de valeurs manquantes",
  cex.names = 0.7
)
```

Proportion moyenne de NA par pays



Le nombre de pays étant important, on peut plus simplement regrouper les pays selon le pourcentage de possession de valeurs manquantes. On établit 3 groupes : le premier entre 0 et 40% de valeurs manquantes, le deuxième entre 40 et 60% et le dernier entre 60 et 100%.

```
groupes <- cut(
  pct_NA_par_pays,
  breaks = c(-Inf, 40, 60, Inf),
  labels = c("< 40%", "40-60%", "> 60%")
)
```

```
table(groupes)
```

```
groupes
< 40% 40-60% > 60%
   19    56     5
```


```
pct_groupes <- tapply(pct_NA_par_pays, groupes, mean)
```

```
pct_groupes
```

```
< 40%    40-60%    > 60%
32.90932 49.22339 64.91339
```

```
barplot(
  pct_groupes,
  col = 'orange',
  main = "Proportion moyenne de NA par groupe de pays",
  ylab = "% de valeurs manquantes"
)
```

Proportion moyenne de NA par groupe de pays



On peut ainsi noter une grande quantité de valeurs manquantes qui nous pénalisera dans la suite de l'étude si on décide de simplement supprimer les données des étudiants qui ne répondent parfois pas à certaines questions. On se proposera alors d'imputer les données par la moyenne.

```
# Sélection des variables quantitatives
vars_quanti <- data_etude %>%
  select(RELATST, TEACHSUP, ESCS,
         ST016Q01NA, ST272Q01JA,
         EXPWB, MOY_MATH, MOY_READ,
         MOY_SCIE, MOY_GENERALE, ANXMAT, BELONG, BULLIED)

# Fonction d'imputation par la moyenne
impute_mean <- function(x){
  x[is.na(x)] <- mean(x, na.rm = TRUE)
  return(x)
}


vars_quanti_imp <- as.data.frame(lapply(vars_quanti, impute_mean))

# Réintégration dans le dataset
data_etude_imp <- data_etude
data_etude_imp[, names(vars_quanti_imp)] <- vars_quanti_imp
```

Partie 1

```
vars_psy <- data_etude_imp %>%
  select(RELATST, TEACHSUP, BELONG, BULLIED, ANXMAT)


cor_psy <- cor(vars_psy)
corrplot(cor_psy, method="number", type="upper")
```



```
res_pca_psy <- PCA(scale(vars_psy), graph = FALSE)
```

```
fviz_eig(res_pca_psy)
```

Warning in geom_bar(stat = "identity", fill = barfill, color = barcolor, : Ignoring empty aesthetic: `width`.




```
fviz_pca_var(res_pca_psy, col.var = "contrib")
```

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
 i Please use `linewidth` instead.
 i The deprecated feature was likely used in the ggpubr package.
 Please report the issue at <<https://github.com/kassambara/ggpubr/issues>>.

Warning: `aes\_string()` was deprecated in ggplot2 3.0.0.
 i Please use tidy evaluation idioms with `aes()`.
 i See also `vignette("ggplot2-in-packages")` for more information.
 i The deprecated feature was likely used in the factoextra package.

Please report the issue at <https://github.com/kassambara/factoextra/issues>.



Partie II

```
cor(data_etude_imp$TEACHSUP, data_etude_imp$MOY_MATH)
```

```
[1] -0.03463762
```

```
cor(data_etude_imp$RELATST, data_etude_imp$MOY_MATH)
```

```
[1] 0.0512005
```

```
modele_direct <- lm(MOY_MATH ~ TEACHSUP + RELATST + ESCS,  
                    data = data_etude_imp)
```

```
summary(modele_direct)
```

Call:

```
lm(formula = MOY_MATH ~ TEACHSUP + RELATST + ESCS, data = data_etude_imp)
```

Residuals:

Min	1Q	Median	3Q	Max
-449.63	-61.97	-4.11	58.05	407.87

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	453.5143	0.1161	3905.91	<2e-16 ***
TEACHSUP	-1.9022	0.1119	-17.01	<2e-16 ***
RELATST	6.8618	0.1259	54.50	<2e-16 ***
ESCS	40.8062	0.1010	404.19	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 87.24 on 613740 degrees of freedom

Multiple R-squared: 0.2146, Adjusted R-squared: 0.2145

F-statistic: 5.588e+04 on 3 and 613740 DF, p-value: < 2.2e-16

```
data_etude_imp %>%
  group_by(CNT) %>%
  summarise(
    corr_TEACH = cor(TEACHSUP, MOY_MATH),
    corr_REL = cor(RELATST, MOY_MATH)
  )
```

Warning: There were 11 warnings in `summarise()`.

The first warning was:

i In argument: `corr\_TEACH = cor(TEACHSUP, MOY\_MATH)`.

i In group 10: `CNT = "CAN"`.

Caused by warning in `cor()`:

! the standard deviation is zero

i Run `dplyr::last\_dplyr\_warnings()` to see the 10 remaining warnings.

A tibble: 80 x 3

	CNT	corr_TEACH	corr_REL
	<chr>	<dbl>	<dbl>
1	ALB	0.110	0.157
2	ARE	0.128	0.162
3	ARG	0.00266	0.0293
4	AUS	0.184	0.208
5	AUT	-0.0631	0.0573
6	BEL	-0.0181	0.0534
7	BGR	-0.0551	0.0292
8	BRA	0.0587	0.136
9	BRN	0.115	NA
10	CAN	NA	NA

i 70 more rows

partie III

```
modele_anx <- lm(ANXMAT ~ TEACHSUP + RELATST + ESCS,
  data = data_etude_imp)

summary(modele_anx)
```

Call:

```
lm(formula = ANXMAT ~ TEACHSUP + RELATST + ESCS, data = data_etude_imp)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-3.6570	-0.4140	-0.0021	0.4162	3.1588

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.212033	0.001329	159.55	<2e-16 ***
TEACHSUP	-0.059217	0.001280	-46.26	<2e-16 ***
RELATST	-0.088185	0.001441	-61.20	<2e-16 ***
ESCS	-0.099505	0.001156	-86.11	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.9985 on 613740 degrees of freedom

Multiple R-squared: 0.02412, Adjusted R-squared: 0.02411
F-statistic: 5056 on 3 and 613740 DF, p-value: < 2.2e-16

```
modele_belong <- lm(BELONG ~ TEACHSUP + RELATST + ESCS,  
                    data = data_etude_imp)  
  
summary(modele_belong)
```

Call:

```
lm(formula = BELONG ~ TEACHSUP + RELATST + ESCS, data = data_etude_imp)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.2662	-0.4926	-0.0871	0.3668	4.7325

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.065455	0.001165	-56.21	<2e-16 ***
TEACHSUP	0.037088	0.001122	33.06	<2e-16 ***
RELATST	0.238512	0.001263	188.90	<2e-16 ***
ESCS	0.096224	0.001013	95.03	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.875 on 613740 degrees of freedom

Multiple R-squared: 0.07972, Adjusted R-squared: 0.07971

F-statistic: 1.772e+04 on 3 and 613740 DF, p-value: < 2.2e-16

```
modele_mediation <- lm(MOY_MATH ~ TEACHSUP + RELATST +  
                        ANXMAT + BELONG + ESCS,  
                        data = data_etude_imp)  
  
summary(modele_mediation)
```

Call:

```
lm(formula = MOY_MATH ~ TEACHSUP + RELATST + ANXMAT + BELONG +  
    ESCS, data = data_etude_imp)
```

Residuals:

Min	1Q	Median	3Q	Max
-436.55	-60.44	-2.89	57.53	400.04

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	457.1442	0.1164	3925.96	<2e-16 ***
TEACHSUP	-2.9724	0.1101	-27.01	<2e-16 ***
RELATST	4.7185	0.1273	37.07	<2e-16 ***
ANXMAT	-16.1942	0.1102	-146.96	<2e-16 ***
BELONG	2.9984	0.1258	23.84	<2e-16 ***
ESCS	38.9062	0.1003	387.97	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 85.63 on 613738 degrees of freedom

Multiple R-squared: 0.2432, Adjusted R-squared: 0.2432

F-statistic: 3.946e+04 on 5 and 613738 DF, p-value: < 2.2e-16